Universidad Nacional Autónoma de México

Facultad de Ciencias

ALMACENES Y MINERIA DE DATOS DE DATOS

2026-2

Tarea 01 - Data Warehouse

ALUMNOS:

Cruz Campos José Eduardo - 319312087
Martínez Hidalgo Paola Mildred - 319300217
Trujillo Beltrán Zianya Nenetzi - 319210787
Toporek Coca Eric - 314284987

Fecha de entrega:
25 de feberero del 2026

Profesor:
Jessica Santizo Galicia

Ayudantes:
Diego Antonio Villalba Gónzalez
Ares Gael Castro Romero

I. Conceptos

1. Da un ejemplo de Almacén de Datos (de acuerdo con tus intereses, no repetir lo visto en clase) y explica cómo se cumple la definición en tu ejemplo. Incluye: Orientación a temas, Integración de datos, Variabilidad en el tiempo y No volatilidad

El escenario que proponemos es el servicio de música de Spotify. De tal forma que se cumplen los siguientes requerimientos:

- Orientación a temas: La aplicación necesita guardar información sobre sus usuarios, artistas, géneros y canciones más reproducidas.
- Variabilidad en el tiempo: La aplicación mantiene registros históricos que permiten analizar la evolución en las reproducciones de sus canciones de cada usuario por mes y año, el número de reproducciones de cada artista, y los géneros más escuchados de cada usuario a lo largo del tiempo.
- No volatilidad: Se mantiene la no volatilidad puesto que los datos ingresados al almacén de datos no se modifican a pesar de que el usuario cambie de géneros musicales o deje de escuchar ciertas canciones, la historia de reproduccion se mantiene para un análisis futuro.

2. Explica con tus propias palabras la diferencia entre un almacén de datos y una base de datos transaccional:

- Una OLTP se utiliza para operaciones como escritura, actualizacion y lectura de los datos actuales. En este caso es posible eliminar y actualizar datos que ya existían puesto que en una OLTP se guardan los datos más recientes.
  A diferencia de un almacén de datos que no puedes 'actualizar' datos que ya estaban escritos puesto que en un data warehouse solo se agregan datos y se consultan esos datos, su objetivo es respaldar datos históricos.
  Lo que tienen en común es que en ambas se consultan los datos, pero en el data warehouse se consultan los datos para anlizarlos tomando en cuenta el tiempo que llevan almacenados, y en un OLTP se consultan los datos más recientes para poder operar sobre ellos.
- Un esquema estrella:
  El esquema estrella es una forma de organizar un data warehouse para facilitar la comprension y análisis al momento de hacer consultas de datos. El esquema estrella permite relacionar los hechos a través de tablas de dimensiones. El esquema estrella es un modelo de organización de los datos implementado en un data warehouse para estructurar los datos de manera eficiente.
- Un cubo OLAP:
  Un cubo OLAP es una estructura de datos multidimensional que se utiliza para analizar los datos de un data warehouse; es decir, no almacena datos nuevos sino que utiliza los datos almacenados en un data warehouse y los organiza en dimensiones para analizarlos.
- Un Data Lake:
  Un data lake no hace limpieza de los datos antes de registrarlos en el almacen de datos, es decir, que todos los datos que captura los almacena en su formato original, es decir que almacena todos los datos independientemente de cómo estén estructurados o si hay datos duplicados o vacíos.
  A diferencia de un data warehouse, a los datos extraídos se les hace una transformación de limpieza donde se eliminan los datos duplicados, verifica que sean datos consistentes y borra datos vacíos para posteriormente almacenarlos.
  Un data warehouse exige que todos los datos sean consistentes que a diferencia de un data lake no transforma su información y unicamente almacena todo lo capturado.

II. Escenario

El Instituto de Matemáticas de la Universidad Nacional Autónoma de México desarrolla y analiza modelos matemáticos mediante simulaciones numéricas, orientadas al estudio de ecuaciones diferenciales, sistemas dinámicos, procesos estocásticos y métodos numéricos.

Cada ejecución de simulación genera información distribuida que se encuentra en registros del clúster, bitácoras de ejecución, archivos de resultados y reportes de uso de recursos computacionales. Actualmente, esta información no está integrada, lo que dificulta el análisis histórico y la toma de decisiones estratégicas.

Por lo anterior, el Instituto te contrata para diseñar un Almacén de Datos que permita analizar el uso de recursos, el comportamiento de las simulaciones y su evolución a lo largo del tiempo.

III. Resuelve los siguientes ejercicios

1. Menciona qué beneficios tendrá utilizar un Almacén de Datos en un entorno de cómputo científico, justifica.

   Tiene ventaja implementar un almacén de datos en un entorno de cómputo científico debido a la gran cantidad de datos resultado de las simulaciones numéricas, como los registros del clúster, bitácoras de ejecución, archivos de resultados, reportes finales del uso de recursos computacionales. El usar un almacén de datos es una forma más estructurada de integrar y almacenar la información de las simulaciones, de esta forma se mantienen registros históricos que pueden ser consultados sin ser modificados con el paso del tiempo, y esto facilita el análisis del comportamiento y la comparación de los resultados obtenidos en distintos periodos de ejecución.

2. Indica qué usuarios utilizarían este Almacén de Datos y con qué propósito, justifica.

   Principalmente los investigadores que están realizando las simulaciones de modelos matemáticos, puesto que ellos son los que necesitan comparar la información de los distintos resultados obtenidos a través del tiempo y con eso definir conclusiones.
   También los administradores o personal de soporte técnico para dar mantenimiento al almacén de datos y gestionar el uso de recursos.

3. Escribe al menos cinco preguntas que el Instituto desearía responder en términos de análisis.

   ¿Cuánto ha evolucionado en los ultimos 5 años el tiempo de ejecución de las simulaciones en sistemas dinámicos?
   ¿Cuál ha sido el menor tiempo requerido para resolver una ecuación diferencial en el ultimo año?
   ¿Qué tipo de proceso estocástico presenta mayor variabilidad en sus resultados?
   ¿Qué metodo numérico es el más eficiente para calcular una ecuación diferencial respecto al tiempo de ejecución?
   ¿Cuál ha sido el consumo promedio de recursos computacionales por tipo de simulación realizada?

4. Describe qué datos históricos almacenaría el Data warehouse del Instituto de Matemáticas y qué decisiones estratégicas apoyaría.

   Almacenaría resultados de cada una de las simulaciones, registro de los recursos computacionales empleados en cada ejecución, registros de clúster, bitácoras de cada ejecución y tiempos de ejecución asociados a cada modelo. Esta información apoyaría para comparar resultados de cada simulación, poder encontrar patrones y determinar decisiones estratégicas como la optimización del uso de recursos computacionales, planificación y mejoras a las futuras simulaciones así como mejoras en los modelos numéricos empleados.

5. Define el hecho principal del modelo multidimensional.

   El hecho principal sería la ejecucion de las simulaciones, pues eso genera los datos que podemos contabilizar, como el tiempo de ejecución, resultados numéricos, recursos, etc.

6. Explica qué representa una fila en la tabla de hechos y da cinco ejemplos.

   Una fila en una tabla de hechos representa un único evento o transacción que es registrada a un cierto nivel de detalle (su granularidad) [1]. Por ejemplo, los siguientes:

   - Un producto escaneado en una caja de un supermercado.
   - Una compra o retiro realizada por una tarjeta de crédito o cuenta de débito bancaria.
   - El alta o la baja de un paciente en un hospital.

- La entrega de un paquete enviado, registrada a través de su escaneo.
- La ejecución de una simulación de un modelo matemático.

7. Se consideran los siguientes niveles de granularidad para el hecho *Ejecución de Simulación:*

   - Una fila por simulación científica.
   - Una fila por ejecución completa de simulación.
   - Una fila por paso iterativo interno.

   Selecciona la granularidad adecuada y justifica por qué es preferible a las demás.

   En este caso conviene trabajar con una granularidad media, es decir, una fila por ejecución completa de simulación. Esto permite tener información suficientemente detallada para analizar el uso de recursos, tiempos de ejecución y comportamiento, sin generar una cantidad excesiva de datos como ocurriría si se registrara cada paso iterativo interno.

   Por otro lado, usar una fila por simulación científica sería demasiado general y no permitiría comparar ejecuciones individuales. Por eso, la granularidad por ejecución completa resulta más equilibrada y útil para el análisis.

8. Explica cuándo sería adecuada una granularidad alta y cuándo una baja, incluyendo sus ventajas y desventajas.

   - **Ganularidad alta:** Este tipo de granularidad es adecuada cuando necesitamos consultas muy detalladas. Por ejemplo, si queremos saber cuántas iteraciones fueron necesarias para que una simulación llegara a un resultado correcto o estable. En este caso se requiere mucha precisión, por lo que conviene guardar información de cada paso interno.

     La ventaja es que permite análisis muy específicos y detallados. La desventaja es que genera una gran cantidad de datos, lo que puede hacer más pesado el almacenamiento y las consultas.
   - **Granularidad baja:** Este tipo de granularidad es adecuada cuando solo necesitamos información más general, como saber cuántas simulaciones se ejecutaron en un mes o la evolución del tiempo de ejecución en las últimas 5 simulaciones. Aquí no se necesita tanto detalle, sino información más global.

     La ventaja es que el almacenamiento es menor y las consultas son más rápidas. La desventaja es que no permite analizar el comportamiento interno o detalles específicos de cada ejecución.

9. Dibuja el esquema estrella correspondiente al escenario. Considera que:

   a) Debe haber al menos cuatro medidas numéricas.
   b) Deben definirse al menos cinco dimensiones, incluidas Tiempo y Simulación.
   c) Deben indicarse los atributos relevantes de cada dimensión.

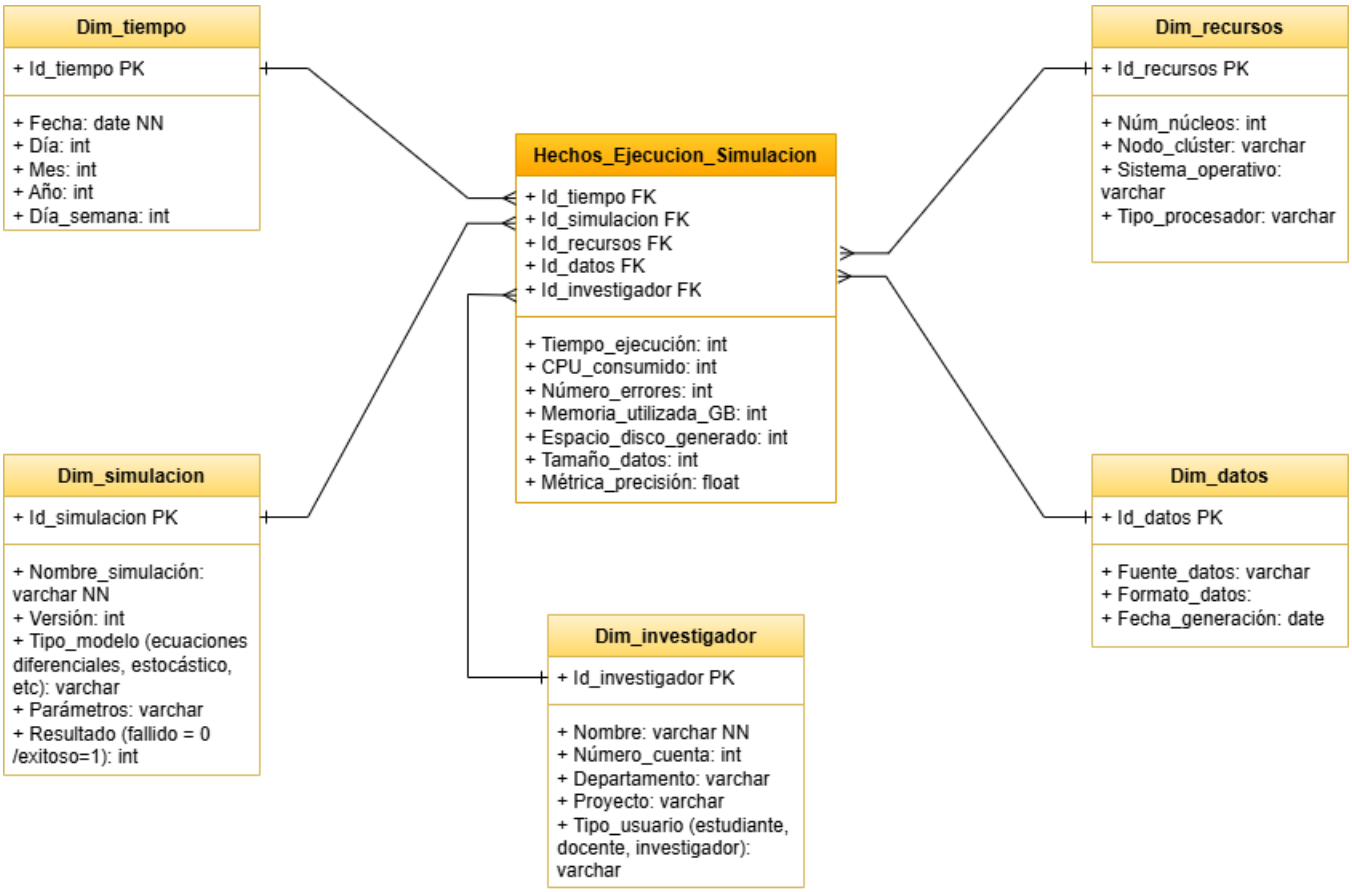

Figura 1: Esquema estrella

10. Describe las capas de la arquitectura de un Almacén de Datos.

    - **Data Source:** Primero se recopila información de varias fuentes como archivos de texto, bitácoras, registros, etc. Una vez que se recopilan se integran a un único sistema.
    - **Data Staging:** En esta capa es donde se lleva a cobo el proceso ETL. En esta parte se extráen los datos brutos de varias fuentes, se transforman mediante la limpieza, el formateo y la estructuración. Una vez hecho lo anterior se cargan en el almacén de datos para su análisis.
    - **Data Storage:** Aquí se encuentra el Data Warehouse como tal. La información ya está integrada y organizada, por ejemplo en tablas de hechos y dimensiones. También pueden haber Data Marts, que permiten trabajar con áreas específicas sin afectar el almacén principal.
    - **Data Presentation:** Finalmente esta capa permite a los usuarios recuperar y analizar datos del almacén, como realizar consultas, generar reportes, análisis predictivos, etc.

    Esta arquitectura es ideal para proyectos a gran escala donde se requiere escalabilidad, flexibilidad y capacidad para manejar volúmenes masivos de datos. [2]

11. Explica el rol de cada capa en el contexto del cómputo científico.

    - **Data Source:** En el escenario dado, las fuentes de datos provienen de los registros de clúster, las bitácoras de ejecución, los archivos de resultados y los reportes de uso de recursos computacionales generados por las diversas ejecuciones de una simulación.
    - **Data Staging:** En esta capa se realizaría los ETL correspondientes para poder dar un estándar adecuado a los datos, podemos suponer que las fuentes tienen una relación entre sí, como una bitácora de ejecución

asociada al registro en un clúster que derivó en un archivo de resultados, la elección de diseño de como serán cargados los datos recae a criterio, se puede tener un archivo que reúna toda la información en un único formato como un csv o json, o en su defecto tener diferentes archivos de acuerdo al mapeo previo, asegurando que se responda de manera unificado a los campos que los relacionan entre sí.

- **Data Storage:** La información limpia pasa a ser almacenada a un Almacén de Datos,realmente no hay mucho que agregar aquí.
- **Data Presentation:** Plataforma en la que los investigadores, pueden tener interacción, realizar consultas, crear tableros y hacer labores de análisis de acuerdo a sus necesidades.

12. Indica dónde se implementa el modelo estrella. El modelo estrella se encuentra implementado en la **capa de almacenamiento**. Dado que esa es la capa que recibe la información limpia, para almacenarse como tal debe de seguir un diseño congruente.

IV. Detección de errores

Plantea y describe dos errores de diseño posibles en un Almacén de Datos para este escenario. Los errores no deben impedir la ejecución de consultas, pero sí producir resultados incorrectos o engañosos.
Para cada error, indica:

- Un ejemplo de consulta donde el error sea evidente.
- Cómo corregirías el error (ETL o Modelo). Escribe detalladamente los pasos a seguir así como tu solución.

1. **La dimensión de cambio lento**
Consideremos que un investigador inicie su trayectoria como doctorante en el departamento de Topología Diferencial, pero eventualmente es promovido a investigador principal en el departamento de Sistemas Dinámicos. A pesar de que sean campos relacionados entre sí, modelos completamente ajenos pueden ser usados en los recursos de cómputo. Si nuestro almacén de datos está diseñado para únicamente sobreescribir los registros con información nueva, se le conoce como dimensión de cambio lento en tipo 1 [1]. En el ejemplo planteado todas las investigaciones previas de nuestro investigador serían asignadas a su departamento actual. Veamos el siguiente query a nuesto almacén:

```sql
SELECT
r.Departmento,
    SUM(f.CPU_consumido) AS Total_Compute_Time
FROM Hechos_Ejecucion_Simulacion f
JOIN Dim_investigador r ON f.id_investigador = r.id_investigador
JOIN Dim_tiempo t ON f.id_tiempo = t.id_tiempo
WHERE t.Anio = 2024
GROUP BY r.Departmento;
```

Este query como tal funciona pero tomará los datos más recientes y el departamento de Sistemas Dinámicos obtendrá resultados inflados.
La solución: Se debe de implementar una dimensión de cambio lento de **tipo 2** para nuestra dimensión de investigador, esto involucra agregar nuevas columnas para mantener observavilidad the la validez historica , creando una nueva fila cada vez que un atributo cambia en lugar de sobreescribirse. Los pasos a seguir son los siguientes:

- Modificar la dimensión investigador que contenga los siguientes cambios:
  - `Fecha_Inicio`
  - `Fecha_Final` (Alguna fecha inalcanzable por defecto como 31-12-9999)
  - `Es_Actual`

- Asegurarse que la llave primaria de un investigador sea su número de cuenta.
- Actualizar los ETL de forma que pueda manejar la lógica de cerrar viejos registros e insertar nuevos. Asi como cargar el hecho acorde a la fecha correspondiente de la ejecución.

2. **Mezcla en granularidad.**
Consideremos que en diseño se quieren definir los hechos de la ejecución de una simulación como el tiempo total de ejecución en la misma tabla que detalles de más bajo nivel como el tiempo de uso de CPU por nodo en un cluster. Digamos que una simulación puede usar múltiples nodos al mismo tiempo de manera paralela. Por lo que el proceso ETL debe de crear 10 filas para una ejecución de una simulación para capturar el uso de CPU por cada nodo. Veamos el siguiente query:

```sql
SELECT
    d.Tipo_Modelo,
    SUM(f.Tiempo_Ejecucion) AS Tiempo_Total_Transcurrido
FROM Hecho_Ejecucion_Simulacion f
JOIN Dim_simulacion d ON f.id_simulacion = d.id_simulacion
JOIN Dim_Tiempo t ON f.id_tiempo = t.id_tiempo
WHERE t.Mes = 2 AND t.Anio = 2026 AND d.Tipo_Modelo = 'Proceso Estocastico'
GROUP BY d.Tipo_Modelo;
```

Lo que sucede aquí es que `Tiempo_Total_Transcurrido` regresará cifras infladas si un proceso estocastico tomo el tiempo total en 10 diferentes recursos. Esto gracias a que la arquitectura mezcla una fila por nodo y una fila por ejecución en términos de granularidad.
La solución: Asegurar que la granularidad es uniforme para todos los trabajos, o en su defecto particionar los hechos de acuerdo a la granularidad, una a más alto nivel, otra a más bajo nivel, donde se guarda la duración total y el total de datos escritos en la primera y el uso de recursos por nodo en la segunda.

- Define dos tablas de hechos para cada tipo de granularidad, como se está descrito anteriormente.
- Asegurar que ambas tablas poseen las mismas dimensiones de manera compartida.
- Modificar el ETL para que tome las bitácoras de los cluster y envíe los titulares a la tabla de hechos en alto nivel, así como el detalle de telemetría por cada nodo para que se envíe a la tabla de bajo nivel.
- Reestructurar las consultas en la capa de análisis de acuerdo al detalle que se quiera tener.

Repositorio GitHub: `https://github.com/ZyanT28/Almacenes_Mineria_Datos.git`

Referencias

[1] Ralph Kimball and Margy Ross. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. Wiley, 3 edition, 2013.

[2] Pykes K. Arquitectura de almacenes de datos: Tendencias, herramientas y técnicas. `https://www.datacamp.com/es/blog/data-warehouse-architecture`, 2025. [Internet; access: 2026-02-21].